

~9.5M
Contratti ANAC

781
Positivi etichettati

2%
Appalti corrotti

nnPU LightGBM
Modello migliore

~ 22×
Lift

CONTESTO

L'obiettivo dello studio è quello di utilizzare l'informazione presente nei dati per stilare un ranking di coefficiente di rischio relativo agli appalti pubblici. Il dataset finale è ottenuto da diverse fonti:

- ANAC:** 19 dataset tematici, ciclo di vita completo dell'appalto (2008–2025)
- ISTAT:** disoccupazione, omicidi, reddito IRPEF pro capite a livello provinciale
- OpenGA:** sentenze definitive TAR / Consiglio di Stato.

Si sono ricavati i tre dataset relativi alle tre fasi del ciclo di vita dell'appalto: apertura del bando (M1); assegnazione (M2); esecuzione (M3).

Dataset	Bandi	Variabili	P	N	U per fold
M1	9 468 795	24	781	1 817	10 650
M2	3 469 880	40	496	1 045	6 386
M3	1 129 233	60	210	280	3 122

PU LEARNING

Nel dominio degli appalti pubblici l'assenza di una condanna non implica regolarità: molti contratti sono semplicemente *non osservati*.


Il problema viene quindi formulato come **PNPU Learning**:

- P:** appalti con condanna definitiva;
- N:** appalti scagionati;
- U:** contratti senza etichetta.

Invece di trattare tutti gli esempi non etichettati come negativi, il modello stima la quota di positivi nascosti tramite la prior $\pi = P(Y = 1)$, utilizzata per bilanciamento, calibrazione e validazione.

L'integrazione di esempi negativi certi migliora sistematicamente le performance rispetto al PU learning standard.

L'uso di questo framework è giustificato anche dalla poca separabilità mostrata dai bandi appartenenti alle 3 diverse classi, P, N e U, come si può vedere nel seguente grafico UMAP con distanza di Gower:



LA FRAZIONE DI CORROTTI

La prior $\pi = P(Y = 1)$ rappresenta la quota reale di appalti corrotti, inclusi quelli non osservati.

Gli stimatori classici assumono un regime *SCAR*, in cui i positivi etichettati sono un campione casuale dei positivi reali. Nel caso ANAC questa ipotesi è irrealistica: le condanne dipendono dalle caratteristiche del bando (*SAR*).

Per questo viene adottato **PULSNAR**, specificamente progettato per il regime SAR e risultato il più stabile nei tre dataset.

- frazione plausibile di corrotti: $\sim 0.5\% - 5\%$;
- valori centrali stimati: $\sim 1\% - 2\%$;
- coerenza con la letteratura empirica italiana.

La prior operativa utilizzata nei modelli è:

$$\hat{\pi}_{op} = 0.02$$

LIGHTGBM nnPU

I modelli sono stati stimati in convalida incrociata e valutati su prestazioni out-of-fold per garantire la generalizzabilità dei risultati. Dal confronto tra diversi approcci PU/PNPU (*Biased Learning*, EM-like, Bagging PU, PUET). In tutti i dataset, l'inclusione dei negativi certi (**PNPU**) a peso pieno migliora stabilità e capacità discriminativa rispetto al PU standard.

Modello selezionato: LightGBM nnPU

- funzione di perdita specifica per il PU learning;
- utilizza la prior π per correggere il contributo degli esempi non etichettati;
- evita l'assunzione irrealistica $U \equiv N$;

Metriche di valutazione

Lift@1%: quante volte i contratti nel top 1% degli score contengono più irregolarità rispetto a una selezione casuale (*baseline* = $1 \times$);

PR AUC: qualità dell'ordinamento sulla classe positiva rara, più informativa della ROC AUC in contesti fortemente sbilanciati (*baseline* $\approx \pi = 0.02$).

	M1	M2	M3
Lift@1%	$17 \times$	$17 \times$	$22 \times$
PR AUC	0.35	0.39	0.56

INTERPRETABILITÀ E ROBUSTEZZA

Calibrazione e stabilità

Le probabilità sono rese confrontabili tramite calibrazione, sebbene la bassa prior ($\pi = 0.02$) mantenga gli score compressi, rendendo il ranking percentuale più informativo dei valori assoluti.

La solidità di tale impianto è confermata dal **bootstrap** stratificato: il ranking mostra elevata stabilità, con i contratti ad alto rischio che rimangono consistenti tra le repliche.

La *conformal prediction* evidenzia comunque la poca separabilità intrinseca ai dati, con un'incertezza che cresce nella coda destra della distribuzione.

Interpretabilità

Le variabili più rilevanti sono coerenti tra i dataset e con la letteratura economica sulla corruzione.

Rango	M1	M2	M3
1	importo del lotto	importo del lotto	importo del lotto
2	durata finestra d'offerta	ritardo aggiudicazione	presenza di delega
3	presenza di delega	offerte ammesse	ritardo aggiudicazione
4	importo complessivo	ribasso offerto	importo complessivo
5	tasso disoccupazione	importo complessivo	scostamento costo pianificato

APPALTI

APPalti è un'applicazione interattiva che implementa il modello per la valutazione del rischio corruttivo negli appalti italiani.

Il sistema calcola lo score **on-the-fly** in base ai dati inseriti dall'utente: il modello si adatta dinamicamente alle variabili disponibili, garantendo l'operatività anche con set informativi incompleti.

Il rischio è restituito come **rango percentile** rispetto alla distribuzione storica ANAC, facilitando la traduzione in classi di intervento prioritarie.

Il **bootstrap** fornisce un intervallo di confidenza 5°–95° del rank, misurando la stabilità dello score su repliche della distribuzione storica.

