

Rilevazione di frodi negli appalti pubblici italiani: un approccio di Positive-Unlabeled Learning

Laboratorio di Statistica con le Aziende • Gruppo “L’Ipotesi Alternativa”
Davide Bortoletto, Giorgia Caicchiolo, Gabriele Paganelli, Gianmarco Rosa

Introduzione

La corruzione negli appalti pubblici è una delle principali minacce all’efficienza della spesa pubblica e alla fiducia dei cittadini nelle istituzioni. In Italia, il fenomeno è monitorato dall’Autorità Nazionale Anticorruzione (ANAC), che raccoglie e pubblica dati dettagliati sui contratti di tutte le stazioni appaltanti nazionali. Nonostante questa disponibilità informativa, identificare preventivamente i bandi a maggior rischio di irregolarità rimane una sfida aperta: solo una frazione esigua risulta associata a procedimenti giudiziari conclusi, mentre la grande maggioranza è priva di qualsiasi etichetta.

Questo lavoro affronta il problema attraverso un approccio quantitativo articolato in tre fasi. Nella prima, è stato costruito un dataset originale integrando i dati ANAC con indicatori territoriali provinciali dell’ISTAT, accompagnato da un’analisi esplorativa preliminare. Nella seconda, sono stati stimati modelli predittivi nell’ambito del *Positive-Unlabeled (PU) Learning*, paradigma progettato per contesti in cui gli esempi etichettati sono pochi e la maggior parte delle osservazioni è priva di etichetta. Nella terza, i risultati sono stati analizzati e interpretati, e il modello selezionato è stato integrato in un’applicazione interattiva per l’uso operativo.

Il risultato finale non è una classificazione binaria, bensì un ordinamento relativo dei bandi per livello di rischio. Questo strumento può supportare le autorità di controllo nella concentrazione delle risorse ispettive sui contratti più a rischio.

Il resto del report è organizzato come segue. La Sezione 1 descrive le fonti dei dati e le operazioni di integrazione. La Sezione 2 presenta l’analisi esplorativa. La Sezione 3 introduce il *framework* di *PU learning* e illustra la stima della *prior* di classe. La Sezione 4 descrive i modelli e ne confronta le prestazioni. La Sezione 5 presenta l’analisi a posteriori e il modello selezionato. La Sezione 6 descrive l’applicazione interattiva.

1 Costruzione del *dataset* e definizione delle etichette

1.1 Il *dataset* in sintesi

Il prodotto finale di questa fase è un archivio di quasi 9 500 000 bandi pubblici italiani, ciascuno descritto da 66 variabili, di cui circa 2600 dotati di un’etichetta certa che indica se il bando sia stato condannato o scagionato da un’autorità competente. Partendo da questo archivio, sono

stati costruiti tre *dataset* (M1, M2, M3), corrispondenti a tre momenti nel ciclo di vita di un appalto, che alimentano i modelli descritti nei capitoli successivi.

Le scelte metodologiche più rilevanti sono state: l'esclusione di informazioni che avrebbero reso il modello artificialmente accurato (perché rivelerebbero a posteriori che la corruzione era già nota); l'adozione di criteri simmetrici per eliminare bandi non confrontabili; il trattamento dei dati mancanti come informazione e non come semplice lacuna; e l'assegnazione dei blocchi per la convalida incrociata, condivisa tra tutti i modelli. L'architettura a tre orizzonti temporali permette di quantificare l'apporto incrementale di ciascuna fase e di costruire uno strumento utilizzabile anche quando il bando è ancora in corso.

1.2 Fonti dei dati

I dati provengono da tre fonti pubbliche distinte.

ANAC: Autorità Nazionale Anticorruzione. La fonte principale è la Banca Dati Nazionale dei Contratti Pubblici (<https://dati.anticorruzione.it/>), che pubblica in formato aperto i dati relativi a tutti i contratti dotati di CIG dal 2008 al 2025. Da questo portale sono stati acquisiti diciannove *dataset* tematici, ciascuno corrispondente a una fase specifica del ciclo di vita dell'appalto. Quasi tutti sono stati inclusi nel *dataset* finale: pochi sono stati scartati per insufficiente copertura, e altri per il rischio di introdurre informazioni che rivelerebbero la corruzione solo a posteriori.

Tra i *dataset* scartati figura quello degli SmartCIG, bandi di valore ridotto che fino al 2024 godevano di procedure semplificate. L'esclusione risponde a una valutazione metodologica: poiché lo SmartCIG è stato abolito, includerlo avrebbe introdotto un'incoerenza strutturale tra i dati storici su cui il modello è addestrato e i contratti futuri a cui sarà applicato.

ISTAT: variabili territoriali di contesto. Per descrivere il contesto socio-economico e di legalità, sono stati integrati tre indicatori provinciali a frequenza annuale: il tasso di disoccupazione, il tasso di omicidi per centomila abitanti e il reddito IRPEF pro capite, riferiti all'anno precedente alla pubblicazione del bando. La scelta di usare questi indicatori, anziché includere la provincia come variabile categoriale, è deliberata: inserire le province come effetti fissi legherebbe la propensione alla corruzione a un'etichetta geografica immutabile. Indicatori come il tasso di disoccupazione o di omicidi cambiano nel tempo, e con essi cambia il rischio atteso, consentendo al modello di generalizzare a scenari futuri.

Giustizia Amministrativa: portale OpenGA. L'etichettatura dei bandi è ottenuta dal portale *OpenGiustiziaAmministrativa* (<https://openga.giustizia-amministrativa.it/>), che pubblica in formato aperto ricorsi e sentenze del TAR e del Consiglio di Stato in materia di contratti pubblici. Sono stati selezionati esclusivamente i ricorsi conclusi con esito di accoglimento o rigetto, escludendo le decisioni intermedie o procedurali.

1.3 Preparazione e integrazione dei dati

La costruzione del dataset ha richiesto scelte su quali bandi includere, come trattare le informazioni incomplete e come verificare la coerenza interna dei dati.

Sul fronte della selezione, due criteri guidano l'inclusione. Il primo riguarda le riaggiudicazioni: quando un contratto è stato risolto e la gara riaffidata, si utilizza sempre la prima aggiudicazione, quella originariamente viziata nei casi di corruzione; le variabili che segnalerebbero una riaggiudicazione sono poi state escluse. Il secondo criterio riguarda i bandi con esito non concluso nell'archivio ANAC: sono stati rimossi simmetricamente da tutti i gruppi per evitare che una caratteristica amministrativa accessoria diventasse un segnale spurio. L'impatto è contenuto: si perdono 6 bandi condannati, 26 scagionati e circa 10 000 non etichettati.

Le tabelle ANAC sono storicamente lacunose: la compilazione di molte sezioni è diventata obbligatoria solo progressivamente nel tempo, e l'assenza di un valore spesso non è casuale, ma segnala che una certa fase del ciclo di vita non si è ancora verificata, o che il valore stesso non sia applicabile all'appalto in questione. I valori mancanti sono quindi trattati come categoria informativa a sé stante, dove possibile. Sono state prodotte due versioni di ciascun dataset: una nella forma originale, e una con i valori mancanti gestiti tramite categorizzazione esplicita o imputazione, per i modelli che richiedono campi completamente compilati.

L'integrità interna è stata infine verificata tramite una serie di controlli di coerenza. Ad esempio, alcuni bandi presentavano intervalli di tempo negativi tra pubblicazione e aggiudicazione, dovuti al caricamento retroattivo di contratti antecedenti il 2008: in questi casi il valore è stato invalidato senza eliminare il bando. È stato inoltre verificato che nessun bando comparisse simultaneamente nelle liste dei condannati e degli scagionati, e che non vi fossero CIG duplicati.

1.4 Etichettatura

Il problema rientra nel *framework Positive-Unlabeled* (PU) learning: si dispone di esempi certi appartenenti alla classe di interesse (bandi corrotti) e di un vasto insieme di esempi senza etichetta. Il *dataset* include inoltre anche bandi scagionati con certezza giudiziaria, configurando un problema PNPU (*Positive-Negative-Unlabeled*).

Le etichette positive corrispondono a bandi per cui esiste un provvedimento che ha accertato l'irregolarità: risoluzioni nell'archivio ANAC per reato o recesso antimafia, e sentenze TAR di accoglimento per ragioni connesse all'aggiudicazione. Le etichette corrispondono all'ultima sentenza disponibile: si è tenuta solo la sentenza del Consiglio di Stato, dove applicabile. La presenza di un ricorso dovrebbe garantire che i bandi scagionati abbiano ricevuto un grado di scrutinio comparabile a quello dei condannati.

Nel *dataset* risultante vi sono 781 bandi positivi (condannati), 1 817 negativi (scagionati) e circa 9 460 000 senza etichetta.

1.5 Orizzonti temporali: i tre *dataset*

Un appalto pubblico attraversa fasi ben distinte: pubblicazione, aggiudicazione, firma del contratto ed esecuzione. Le informazioni disponibili cambiano radicalmente da una fase all'altra, e costruire un unico *dataset* che le mescoli introdurrebbe sistematicamente dati mancanti per i bandi non ancora completati, rischiando che il modello impari a riconoscere la corruzione dal tipo di dato mancante anziché dalle caratteristiche dell'appalto. Sono stati quindi costruiti tre *dataset* separati:

- M1 (Ex ante)** Include tutti i bandi pubblicati, descritti dalle sole informazioni disponibili al momento della pubblicazione: caratteristiche economiche della gara, parametri procedurali, classificazione merceologica, variabili temporali e indicatori territoriali. È il *dataset* più grande ma con le variabili meno informative; è l'unico applicabile quando la gara non è ancora conclusa.
- M2 (Durante)** Restringe l'analisi ai bandi effettivamente aggiudicati e aggiunge le informazioni sull'aggiudicazione: numero di offerte ricevute, caratteristiche dell'aggiudicatario, ribasso offerto.
- M3 (Ex post)** Restringe ulteriormente ai bandi con evidenze di esecuzione e aggiunge le variabili relative alla vita esecutiva: varianti contrattuali, sospensioni, quadro economico a consuntivo, collaudo. È il *dataset* più ricco informativamente, ma con il minor numero di bandi disponibili.

I tre *dataset* sono annidati: ogni bando in M3 è presente anche in M2 e in M1, non viceversa. Questo consente di confrontare il contributo informativo delle diverse fasi a parità di bandi osservati.

1.6 Assegnazione dei blocchi di convalida

Data la bassa numerosità di etichette, viene adottata una convalida incrociata a quattro blocchi stratificati, condivisa da tutti i modelli per garantire confronti diretti. I blocchi sono annidati tra M1, M2 e M3, e ciascuno contiene la stessa proporzione di bandi condannati e scagionati. La dimensione dei campioni di esempi non etichettati per blocco è stata calibrata in base alla stima della *prior* discussa nella Sezione 3, con l'obiettivo di limitare la presenza attesa di positivi nascosti all'interno dei dati di stima.

2 Analisi esplorativa dei dati

2.1 Struttura del dataset e distribuzione delle etichette

Il *dataset* finale comprende 9 468 795 CIG. La progressione verso le fasi successive filtra le gare in misura sostanziale: M2 ne conserva 3 469 880, M3 scende a 1 129 233. La Tabella 1 riassume le dimensioni dei tre *dataset* e la numerosità per blocco di convalida incrociata.

La distribuzione dei bandi nel tempo e tra le province è sostanzialmente quella attesa: i territori più popolosi e economicamente attivi concentrano più appalti, e la variazione temporale

Tabella 1. Dimensioni dei tre dataset e distribuzione delle etichette per blocco di convalida.

Dataset	Bandi totali	Variabili	P (1)	N (0)	Unlabeled per blocco
M1 (ex ante)	9 468 795	24	781	1 817	10 650
M2 (durante)	3 469 880	40	496	1 045	6 386
M3 (ex post)	1 129 233	60	210	280	3 122

segue l’andamento generale della spesa pubblica. Non emergono anomalie che suggeriscano distorsioni nel campione dei bandi, oltre all’ovvio *bias* di selezione per le etichette. Anche la distribuzione degli importi risulta coerente con il contesto analizzato, mostrando una marcata asimmetria: la maggior parte dei bandi presenta valori contenuti, e un numero ridotto di appalti con importo molto elevato.

2.2 Struttura dello spazio delle covariate

La Figura 1 mostra una proiezione bidimensionale dello spazio delle covariate tramite UMAP (*Uniform Manifold Approximation and Projection*), una tecnica di riduzione della dimensionalità che preserva la struttura locale del dato. La distanza utilizzata è quella di Gower, adatta a dati misti con variabili continue, categoriali e binarie.

La riga superiore mostra che i bandi condannati (P) non occupano una regione isolata: sono dispersi all’interno della nuvola di osservazioni non etichettate (U), con sostanziale sovrapposizione rispetto agli assolti (N). Parte degli esempi non etichettati occupa la stessa regione dei condannati e potrebbe essere essa stessa corrotta, il che rende non valida l’assunzione che gli esempi non etichettati coincidano con la classe negativa e giustifica l’adozione del *PU learning* rispetto a un classificatore standard. La dispersione dei bandi corrotti all’interno della nuvola segnala la difficoltà intrinseca del compito: non esiste una separazione netta tra le classi, e qualunque modello predittivo dovrà operare in un contesto di forte sovrapposizione.

Le righe successive riportano alcune variabili ritenute particolarmente rilevanti in fase esplorativa, selezionate perché mostrano *pattern* visivi di separazione più evidenti all’interno della rappresentazione UMAP e consentono quindi di interpretare meglio i principali assi di variazione dello spazio delle covariate.

La riga *CPV* rivela una struttura settoriale visibile, più marcata in M2 e M3. La riga *procedura* mostra la separazione più netta: le quattro tipologie procedurali formano gruppi distinti, suggerendo che il tipo di gara sia uno dei principali assi di variazione. Infine, la riga *importo* evidenzia come i contratti di valore elevato (oltre 1M€) si concentrino in regioni specifiche dello spazio, separate dagli affidamenti di importo minore.

3 Stima della proporzione di positivi

3.1 Il *framework* di *PU learning*

Il *PU learning* nasce per affrontare una situazione comune in molti contesti reali: si dispone di esempi certi di una sola classe di interesse, detta positiva, mentre tutto il resto dei dati è privo




Figura 1. Proiezione UMAP (distanza di Gower) sui tre dataset per diverse variabili di colorazione. Le osservazioni non etichettate sono mostrate su un campione di 10 000 unità.

di etichetta. L’asimmetria è strutturale: sappiamo con certezza che alcuni contratti sono stati condannati, ma non possiamo affermare che tutti gli altri siano regolari. Un appalto senza etichetta può essere genuinamente corretto oppure semplicemente impunito.

Trattare tutti gli esempi non etichettati come negativi certi introdurrebbe un *bias* sistematico, perché alcuni di essi sono in realtà positivi nascosti. Il *PU learning* risolve il problema modellando esplicitamente questa incertezza: invece di assegnare un’etichetta certa ai non etichettati, stima la frazione di positivi tra di essi attraverso la *prior* di classe $\pi = P(Y = 1)$, e stima i modelli tenendo conto di questa ambiguità.

In questo lavoro il problema si presenta nella variante PNPU (*Positive-Negative-Unlabeled*): oltre ai positivi certi e alla vasta massa di esempi non etichettati, sono disponibili anche negativi certi: i bandi scagionati con sentenza definitiva. La loro presenza arricchisce il segnale e, come mostrato nei risultati, migliora sistematicamente le prestazioni rispetto alla sola configurazione *PU*. La stima della *prior* π è il punto di partenza dell’intera procedura: da essa dipendono il bilanciamento delle perdite, la calibrazione degli *score* e la dimensione dei blocchi di convalida.

3.2 Scelta dello stimatore

La *prior* di classe π , ovvero la frazione di bandi corrotti nell’intera popolazione, inclusi quelli ancora impuniti, non è osservabile direttamente. Per stimarla sono stati implementati e confrontati quattro stimatori: Elkan–Noto [Elkan and Noto, 2008], Blanchard et al. [Blanchard et al., 2010], KM2 [Ramaswamy et al., 2016] e PULSNAR [Kumar et al., 2023], applicati ai tre *dataset*.

I primi tre stimatori si basano sull’ipotesi SCAR (*Selected Completely At Random*), secondo cui i positivi etichettati costituiscono un campione casuale dei positivi reali. Nel contesto degli appalti italiani questa ipotesi è chiaramente violata: i 781 bandi positivi disponibili derivano da un processo di selezione che privilegia specifiche tipologie di contratti e aree geografiche.

Si è quindi nel regime SAR (*Selected At Random*), in cui la probabilità di essere identificato come positivo dipende dalle caratteristiche del bando stesso. Questo emerge anche empiricamente: gli stimatori SCAR producono stime altamente instabili e irrealistiche, PULSNAR è l’unico dei quattro progettato per operare in regime SAR ed è quindi adottato come riferimento principale.

3.3 Metodologia e risultati

PULSNAR affronta il regime SAR in due fasi. Prima stima la probabilità che un esempio sia etichettato come positivo tramite un classificatore probabilistico, successivamente raggruppa i positivi in *cluster* tramite un modello a mistura gaussiana, stimando la *prior* come proporzione di esempi non etichettati assegnati a ciascun *cluster*, pesata per la calibrazione locale del classificatore. Il numero di *cluster* è scelto tramite criterio BIC.

L’algoritmo è stato eseguito su campioni ripetuti dei tre *dataset*, ottenendo risultati complessivamente stabili. La Tabella 2 riporta la mediana e l’intervallo di variabilità (IC 95%) delle 30 stime per *dataset*.

Tabella 2. Distribuzione delle 30 stime PULSNAR ottenute con campioni indipendenti.

Dataset	Mediana	IC 95%
M1	1.35%	[0.80%, 4.24%]
M2	1.53%	[0.78%, 6.35%]
M3	0.56%	[0.24%, 12.59%]

Le mediane si collocano tra 0.6% e 1.5%, con variabilità crescente al diminuire del numero di etichette. Per ancorare queste evidenze a un riferimento esterno, la Tabella 3 riporta stime dalla letteratura empirica sulla corruzione negli appalti italiani, che convergono su valori prossimi al 2%.

Tabella 3. Stime della prevalenza di corruzione negli appalti dalla letteratura.

Fonte	Anno	π stimata	Definizione
Conzo et al. (J. Public Econ.)	2020	$\sim 1\%$	Infiltrazione mafiosa
Decarolis & Giorgiantonio (BI QEF 544)	2022	$\sim 2\%$	Condanne
Coviello, Guglielmo, Spagnolo (NBER 28209)	2020	$\sim 2\%$	Condanne

Il *range* plausibile per π nel dataset ANAC verrà esplorato ulteriormente, ma può essere fissato tra 0.5% e 5%: il limite inferiore riflette le sole condanne, il superiore approssima le stime per i lavori pubblici, settore a maggior rischio. La convergenza tra stime interne e letteratura rafforza la credibilità dell’intervallo.

3.4 Scelta operativa della *prior*

Sulla base delle evidenze discusse si adotta il valore operativo di $\hat{\pi}_{\text{op}} = 0.02$. Il valore è coerente con le stime PULSNAR e con la letteratura. L’arrotondamento al 2% risponde a una logica prudenziale: una *prior* leggermente più alta riduce il rischio di contaminazione dei blocchi di convalida con positivi non etichettati. La scelta è affiancata da una griglia di sensibilità che copre l’intero intervallo plausibile (tra 0.05 e 0.5), ed è applicata in modo uniforme a tutti i *dataset*.

Vale infine osservare che la frequenza di etichettatura (la probabilità che un positivo reale sia osservato ed etichettato) calcolabile a partire dalla *prior* risulta molto contenuta: approssimativamente 0.004, 0.007 e 0.009 rispettivamente per M1, M2 e M3, ossia circa un positivo etichettato ogni 240, 140 e 110 reali. Il progressivo aumento da M1 a M3 è coerente con la maggiore disponibilità informativa nelle fasi successive del ciclo di vita.

4 Modelli

Questa sezione descrive i modelli sviluppati per il problema di classificazione con dati parzialmente etichettati. Tutti sono stati validati con convalida incrociata a quattro blocchi stratificati. Per ciascuna famiglia è stata implementata sia la variante PU, basata sui soli

positivi noti e sugli esempi non etichettati, sia la variante PNPU, che integra i negativi certi: il confronto consente di quantificare il contributo informativo delle sentenze di assoluzione.

In tutti i modelli i positivi hanno peso unitario; gli esempi non etichettati assumono peso $\pi(1 - \pi) \approx 0.025$, come suggerito in letteratura. Nella variante PNPU i negativi certi hanno peso unitario; nella variante PU lo stesso peso degli esempi non etichettati.

4.1 I modelli considerati

4.1.1 *Biased Learning*

Il primo approccio è il *Biased Learning*: i dati non etichettati sono trattati come appartenenti alla classe negativa con peso ridotto, tenendo conto del fatto che alcuni di essi potrebbero essere positivi nascosti. Nella variante PNPU i negativi certi sono aggiunti con peso pieno. Il framework è stato applicato con Regressione Logistica, *Support Vector Machine*, *Random Forest* e *Gradient Boosting*, in versione *LightGBM*; per ciascuno è stata ottimizzata una griglia di iperparametri con validazione interna. Il *Gradient Boosting* è l'unico in grado di gestire direttamente i dati mancanti; gli altri modelli sono stati addestrati sui *dataset* preprocessati.

4.1.2 Metodi iterativi *EM-like*

Due approcci iterativi di tipo *EM-like* si ispirano al paradigma dello *Spy-based PU learning* [Liu et al., 2002]: a ogni iterazione, le predizioni sugli esempi non etichettati vengono usate per aggiornarne i pesi, affinando progressivamente la separazione tra le classi.

Le due varianti differiscono nella modalità di aggiornamento. La versione *soft* distribuisce il contributo di ciascun esempio non etichettato proporzionalmente alla fiducia del classificatore: l'aggiornamento graduale riduce il rischio di propagare errori nelle prime iterazioni. La versione *hard* seleziona esplicitamente gli esempi ritenuti negativi con maggiore affidabilità e li incorpora come negativi certi: più selettiva e potenzialmente più discriminativa, ma anche più sensibile a errori di assegnazione. Poiché entrambe richiedono negativi certi come riferimento iniziale, sono state implementate esclusivamente nella configurazione PNPU.

4.1.3 Stimatori nnPU

Un ulteriore approccio si basa sulla funzione di perdita proposta da Kiryo et al. [2017], progettata specificamente per il *PU learning*. L'idea centrale è stimare il contributo dei positivi e dei non etichettati all'errore di classificazione usando π per ricostruire indirettamente l'informazione mancante sulla classe negativa. La formulazione include un meccanismo correttivo che impedisce la sovrastima sistematica del contributo negativo. Nella variante PNPU viene aggiunto un termine corrispondente ai negativi certi.

La solidità teorica è il principale punto di forza: il modello usa tutte le informazioni disponibili in modo coerente con la struttura del problema, senza assumere che i non etichettati siano negativi con rumore. Il *framework* è stato applicato a tre classificatori base: Regressione Logistica, *LightGBM* e Rete Neurale.

4.1.4 *Bagging* PU e PUET

Gli ultimi metodi si basano sul *Bagging*: vengono costruiti numerosi classificatori indipendenti, ciascuno addestrato su tutti i positivi e su un piccolo campione estratto dai non etichettati. Combinando i risultati di molti modelli addestrati su campioni diversi, gli errori dovuti ai positivi nascosti tendono a compensarsi. Non è richiesta la conoscenza di π a priori. Nella variante PNPU i negativi certi sono inclusi stabilmente nell'addestramento con peso maggiore.

Il Bagging PU [Mordelet and Vert, 2014] usa *LightGBM* come classificatore base. Il PUET (*Positive-Unlabeled Extra Trees*) [Wilton et al., 2022] è una variante specializzata con due differenze fondamentali. La prima riguarda il classificatore: *Extra Trees*, alberi con una forte componente casuale nella scelta degli *split*, particolarmente robusti al rumore. La seconda è più profonda: anziché i criteri di impurità tradizionali, il PUET minimizza direttamente lo stimatore del rischio nnPU a ogni nodo, rendendolo l'unico metodo su alberi che ottimizza esplicitamente l'obiettivo del *PU learning*.

4.2 Risultati

I modelli sono valutati mediante due metriche complementari: il Lift@1% e la PR AUC. Il Lift@1% misura quante volte la concentrazione di contratti irregolari tra la quota di osservazioni con punteggio di rischio più elevato (superiore al 99% dei contratti analizzati) superi quella attesa in caso di selezione casuale: un valore pari a $10\times$ indica che, ispezionando soltanto i contratti collocati nella fascia più rischiosa, si individuano dieci volte più casi irregolari rispetto a un'estrazione casuale. Si tratta della metrica più rilevante dal punto di vista operativo, in quanto riflette uno scenario realistico in cui le risorse ispettive sono necessariamente limitate.

La PR AUC valuta invece la qualità dell'ordinamento sull'intera distribuzione degli *score*: a differenza della ROC AUC, che tende a essere eccessivamente ottimistica in presenza di forte sbilanciamento tra le classi, è più sensibile al recupero della classe positiva rara e risulta quindi più informativa nel contesto analizzato. I valori di riferimento per un classificatore casuale sono 1 per il Lift e 0.02 per la PR AUC.

Un primo risultato trasversale è che la variante PNPU eguaglia o supera sempre la variante PU, spesso con minore variabilità tra i blocchi: le assoluzioni giudiziarie sono informative, e ignorarle è una perdita non giustificata. Il valore $\pi = 0.02$ si conferma come scelta robusta e coerente su tutti i *dataset*.

I modelli *EM-like* offrono un risultato metodologico interessante: le varianti *Hard* e *Soft* convergono praticamente sempre all'iterazione zero. Quando i negativi certi hanno qualità giudiziaria, il classificatore addestrato su P vs N assegna score elevati alla quasi totalità degli esempi non etichettati, rendendo superflua l'estrazione iterativa. Il *framework* si riduce di fatto a un *LightGBM* supervisionato sui soli contratti etichettati. Nonostante le riserve teoriche in regime PU, le sue prestazioni empiriche lo mantengono tra i modelli candidati.

La Tabella 4 riporta le prestazioni dei quattro modelli selezionati. Il *Bagging LightGBM* ottiene il *lift* più elevato su M2 e M3, ma con alta variabilità tra i blocchi. Il *LightGBM* supervisionato su P vs N mostra PR AUC alto e stabile; ma va ribadito che non è un modello di *PU learning* e che la sua robustezza teorica in questo regime non è garantita. Il *LightGBM*

$nnPU$ ha la migliore fondazione teorica tra i modelli candidati, adottando la funzione di perdita $nnPU$, con buona stabilità *lift* competitivo. Il PUET presenta la stabilità migliore in assoluto e un PR AUC nettamente superiore, a fronte di un *lift* leggermente inferiore.

Tabella 4. Prestazioni OOF dei quattro modelli candidati.

Modello	M1		M2		M3	
	Lift@1%	PR AUC	Lift@1%	PR AUC	Lift@1%	PR AUC
Bagging LightGBM	17.80	0.402 ± 0.024	18.15	0.433 ± 0.023	21.43	0.591 ± 0.078
LightGBM P vs N	20.95	0.602 ± 0.031	13.49	0.735 ± 0.044	17.86	0.885 ± 0.027
RE LightGBM	17.41	0.355 ± 0.019	17.14	0.389 ± 0.025	21.90	0.556 ± 0.063
PUET	15.75	0.408 ± 0.024	15.73	0.423 ± 0.030	14.76	0.591 ± 0.021

Le prestazioni crescono da M1 a M3 in modo non uniforme: le variabili aggiuntive delle fasi successive sono discriminative, ma la riduzione delle numerosità aumenta l’instabilità delle stime. La selezione del modello finale è demandata all’analisi a posteriori descritta nella Sezione 5.

5 Analisi a posteriori

I quattro migliori modelli sono stati sottoposti a un’analisi estesa che comprende la valutazione del contributo dei negativi certi, la calibrazione delle probabilità, la *conformal prediction*, l’analisi di importanza delle variabili tramite SHAP e una stima *bootstrap* dell’incertezza. L’obiettivo è identificare un modello di riferimento che sia al contempo performante, affidabile e interpretabile.

5.1 Ruolo dei negativi certi: griglia su γ

Per valutare sistematicamente il contributo dei negativi certi all’addestramento, è stata esplorata una griglia di valori del parametro di *mixing* $\gamma \in [0, 1]$, seguendo la formulazione di Sakai et al. [2017]. Al crescere di γ aumenta il peso assegnato ai negativi certi; $\gamma = 0$ equivale a ignorarli del tutto.

I risultati mostrano che $\gamma = 1$ (peso pieno ai negativi certi) è sempre giustificabile. In quasi tutti i casi, ridurre γ non migliora e spesso peggiora le prestazioni, confermando quanto già emerso nel confronto PU vs PNPU: i negativi certi portano informazione reale che non è sostituibile dai soli esempi non etichettati. Si adotta quindi $\gamma = 1$ come configurazione canonica.

5.2 Affidabilità delle stime: calibrazione e *conformal prediction*

I modelli di *PU learning* producono punteggi grezzi senza un’interpretazione probabilistica diretta: la scala dipende dall’architettura e dalla funzione di perdita, e i valori tendono a comprimersi lontano dagli estremi. Per trasformarli in probabilità confrontabili si applica il *Platt scaling* [Platt, 1999]: una regressione logistica monotona stimata in convalida incrociata sui soli contratti etichettati. La qualità della calibrazione è misurata tramite l’ECE (*Expected*

Calibration Error). Prima della correzione l'ECE grezza varia tra 0.11 e 0.35, dopo il *Platt scaling* scende sotto 0.06 per tutti i modelli considerati.

Va tuttavia sottolineato che le probabilità assolute restano schiacciate verso valori bassi per effetto della *prior* ridotta ($\pi = 0.02$). Nella pratica è quindi preferibile fare affidamento sull'ordinamento degli *score*, e in particolare sul rango percentuale globale, piuttosto che sulle probabilità assolute.

La *conformal prediction* [Vovk et al., 2005] completa questo quadro fornendo, per ogni contratto, un insieme di previsione con garanzia formale di copertura: con livello $\alpha = 0.10$, almeno il 90% dei contratti di ciascuna classe riceve un insieme che contiene la vera etichetta. Gli insiemi possibili sono l'insieme con sola etichetta positiva $\{P\}$ (irregolare con alta fiducia), l'insieme con sola etichetta negativa $\{N\}$ (regolare) e l'insieme ambiguo $\{N, P\}$. Per tutti i dataset, gran parte dei contratti finisce nell'insieme ambiguo. Questo non è un fallimento del metodo, ma riflette la difficoltà intrinseca del compito: con una *prior* del 2% e pochi positivi certi per blocco di calibrazione, la distinzione è raramente netta.

5.3 Interpretabilità: analisi SHAP

Per poter interpretare quali variabili influenzino maggiormente i risultati, è stata condotta un'analisi di importanza tramite SHAP sui modelli finali addestrati sull'intero *dataset*. La Tabella 5 riporta le cinque variabili più importanti per il *LightGBM nnPU* sui tre *dataset*.

Tabella 5. Top-5 variabili per importanza SHAP (RE LightGBM), in ordine decrescente di importanza media sui contratti etichettati.

Rango	M1	M2	M3
1	importo del lotto	importo del lotto	importo del lotto
2	durata finestra d'offerta	ritardo nell'aggiudicazione	presenza di delega
3	presenza di delega	offerte ammesse	ritardo nell'aggiudicazione
4	importo complessivo	ribasso offerto	importo complessivo
5	tasso di disoccupazione	importo complessivo	scostamento dal costo pianificato

L'importo del lotto è la variabile più importante in tutti e tre i *dataset*: la dimensione economica della gara è il segnale di rischio più robusto. Le variabili procedurali (durata della finestra d'offerta, ritardo nell'aggiudicazione e numero di offerte ammesse) emergono sistematicamente in M1 e M2, coerenti con i meccanismi di riduzione artificiale della concorrenza descritti in letteratura. Su M3, lo scostamento dal costo pianificato segnala che i sovraccosti in fase esecutiva sono associati a irregolarità. La coerenza complessiva tra le variabili selezionate e i meccanismi teorici della corruzione rafforza la fiducia nella validità delle predizioni.

5.4 Selezione e validazione del modello di riferimento

Alla luce dell'analisi complessiva, il *LightGBM* con funzione di perdita nnPU emerge come modello di riferimento. Combina un *lift* alto con bassa variabilità tra i blocchi, una calibrazione tra le migliori, una copertura *conformal* superiore al 90% e importanza delle variabili tramite SHAP coerenti con la teoria. Rispetto agli altri candidati, il vantaggio decisivo è la fondazione

teorica: è l'unico tra i modelli su alberi che ottimizza esplicitamente un obiettivo progettato per il *PU learning*.

Per quantificare l'incertezza delle stime del modello selezionato è stato condotto un *bootstrap* stratificato con 200 ricampionamenti a partire dai contratti etichettati. Per ciascun ricampionamento il modello viene riaddestrato e gli *score* applicati a un insieme fisso di contratti non etichettati, producendo un intervallo di confidenza al 95% per ognuno. I risultati mostrano una struttura bimodale nell'incertezza: i contratti nella massa bassa della distribuzione hanno intervalli quasi nulli, a indicare un ordinamento stabile; quelli ad alto rischio mostrano ampiezze nell'ordine di 0.01–0.12 su M1/M2, e fino a 0.45 su M3. Questo non inficia la validità dell'ordinamento: i contratti al vertice della distribuzione rimangono stabilmente i più sospetti tra i ricampionamenti. Il segnale è reale, è la stima puntuale di probabilità a essere incerta, non il *ranking*.

6 Applicazione interattiva per la valutazione del rischio

È stata sviluppata un'applicazione interattiva (dal nome evocativo *APPalti*) per la valutazione del rischio corruttivo negli appalti pubblici italiani. Lo strumento consente di inserire le caratteristiche di un singolo appalto e ottenere una stima del rischio relativa rispetto alla distribuzione storica degli appalti ANAC (2008–oggi), ed è progettato per essere accessibile anche a utenti non tecnici.

6.1 Struttura e logica di analisi

L'interfaccia guida l'utente attraverso tre sezioni corrispondenti alle fasi del ciclo dell'appalto. La prima raccoglie i dati di gara (importo, tipologia di procedura, caratteristiche amministrative). La seconda, opzionale, acquisisce i dati di aggiudicazione (numero di offerte, ribasso). La terza, anch'essa opzionale, riguarda l'esecuzione del contratto (varianti, sospensioni, scostamenti economici). L'interfaccia è dinamica: i campi appaiono solo quando rilevanti, adattando il livello di dettaglio alla disponibilità dei dati.

Una volta inseriti i dati, l'applicazione identifica automaticamente il livello informativo disponibile, seleziona il sottoinsieme di variabili pertinenti ed elabora il profilo secondo lo schema del modello di riferimento. Il risultato è espresso come rango percentile rispetto agli appalti storici: un valore di 80 indica che l'appalto risulta più rischioso dell'80% dei casi osservati. Il punteggio è tradotto in quattro classi qualitative (basso, moderato, elevato, molto elevato) per facilitarne l'interpretazione operativa.

6.2 Funzionalità aggiuntive

L'*output* include una rappresentazione grafica del posizionamento dell'appalto nella distribuzione storica, insieme a una sintesi testuale. La stabilità del punteggio può essere valutata tramite *bootstrap*, che stima la variabilità della stima rispetto a possibili sottocampioni dei dati storici. Una spiegazione basata su valori SHAP evidenzia le variabili che contribuiscono maggiormente ad aumentare o ridurre il rischio nel caso specifico. L'applicazione supporta

infine una modalità *batch* per l'analisi di file CSV, restituendo per ogni riga il punteggio e la classe di rischio.

Nel complesso, l'applicazione traduce i risultati del modello in uno strumento operativo capace di gestire diversi livelli di completezza informativa e di operare sia su singoli appalti che su grandi insiemi di dati.

Conclusione

Questo lavoro affronta il problema della rilevazione della corruzione negli appalti pubblici italiani attraverso quattro contributi principali.

Il primo riguarda la costruzione del *dataset*: un archivio originale che integra i microdati ANAC su circa 9 500 000 bandi con indicatori territoriali ISTAT e sentenze del TAR, organizzato in tre configurazioni corrispondenti a diversi orizzonti informativi nel ciclo di vita dell'appalto.

Il secondo consiste nella stima della proporzione di appalti con irregolarità nella popolazione, resa complessa dall'assenza di etichette certe per la maggior parte delle osservazioni. L'analisi converge su un valore operativo del 2%, coerente con la letteratura sulla corruzione negli appalti italiani.

Il terzo contributo è lo sviluppo e la valutazione di modelli predittivi in ambito *PU learning*. Il modello *LightGBM* con funzione di perdita nnPU emerge come riferimento per solidità teorica, stabilità delle prestazioni e coerenza delle variabili selezionate con i meccanismi noti della corruzione.

Il quarto è un'applicazione interattiva che rende il modello accessibile tramite interfaccia, traducendo gli *score* in un punteggio di rischio relativo e offrendo strumenti di spiegazione e analisi di stabilità.

Nel complesso, il lavoro mostra come i dati amministrativi sugli appalti pubblici contengano segnali predittivi di rischio corruttivo estraibili e utilizzabili operativamente, anche in presenza di etichette fortemente parziali.

Per garantire riproducibilità e riusabilità dei risultati, il codice sviluppato sarà reso disponibile quanto prima su *GitHub* al seguente link:

github.com/GabriPaganelli/anac-pu-learning.

A Dizionario delle variabili

Variabile	Descrizione	Fonte	Fase
Variabili ex ante — disponibili alla pubblicazione del bando		<i>presenti in M1, M2 e M3</i>	
importo_lotto	Valore a base d'asta del lotto (€)	CIG	M1
importo_complessivo_gara	Valore totale della procedura (somma dei lotti, €)	CIG	M1
n_lotti_componenti	Numero di lotti della gara	CIG	M1
oggetto_principale_contratto	Tipo di contratto: lavori, servizi, forniture	CIG	M1
tipo_scelta_4cls	Procedura aggregata: aperta, ristretta, negoziata, affidamento diretto	CIG	M1
cpv_macro_categoria	Macro-categoria CPV: lavori, servizi, forniture, IT, ingegneria, sanità	CIG	M1
natura_giuridica_SA	Natura giuridica della SA: PA ente, istituzionale, sanitario, società, ente economico, consorzio, non-profit, altro	Anagrafica SA	M1
sezione_regionale	Sezione ANAC competente: centrale o regionale	CIG	M1
cod_modalita_realizzazione	Modalità di realizzazione (codice ANAC)	CIG	M1
cod_strumento_svolgimento	Strumento di svolgimento della gara (codice; spesso assente)	CIG	M1
finestra_offerta_giorni	Giorni dalla pubblicazione alla scadenza delle offerte	CIG	M1
lag_perfezionamento_giorni	Giorni dalla pubblicazione al perfezionamento formale	CIG	M1
importo_sicurezza_pct	Oneri di sicurezza in % sull'importo del lotto	CIG, Quadro economico	M1
pct_riserva_base	Somme a disposizione nel QE in % del costo core; proxy del margine di contingenza	Quadro economico	M1
flag_urgenza	Procedura urgente (0/1)	CIG	M1
cod_motivo_urgenza	Codice del motivo di urgenza (quasi sempre assente)	CIG	M1
flag_delega	Delega a centrale di committenza (0/1/non noto)	CIG	M1
flag_accordo_quadro	Accordo quadro (0/1)	CIG	M1
flag_ripetizioni	Prestazioni ripetibili previste (0/1)	CIG	M1
settore_speciale	Settori speciali ex D.Lgs. 50/2016: utilities, trasporti, energia (0/1)	CIG	M1

Continua nella pagina successiva

(segue dalla pagina precedente)

Variabile	Descrizione	Fonte	Fase
flag_appalto_riservato	Riservato a categorie protette o economia sociale (0/1)	CIG	M1
tasso_disoccupazione	Tasso di disoccupazione provinciale (anno precedente)	ISTAT	M1
reddito_irpef_procapite	Reddito IRPEF pro-capite provinciale, €, anno precedente	MEF	M1
tasso_omicidi_100k	Omicidi per 100.000 ab. a livello provinciale	ISTAT (BES)	M1
Variabili durante — disponibili dopo l'aggiudicazione		<i>presenti in M2 e M3</i>	
importo_aggiudicazione	Importo definitivo di aggiudicazione (€)	Aggiudicazioni	M2
ribasso_aggiudicazione	Ribasso % rispetto alla base d'asta	Aggiudicazioni	M2
ribasso_spread	Differenza tra ribasso massimo e ribasso aggiudicatario; proxy della competizione	Aggiudicazioni	M2
num_imprese_offerenti	Numero di imprese offerenti	Aggiudicazioni	M2
numero_offerte_ammesse	Offerte ammesse alla valutazione	Aggiudicazioni	M2
numero_offerte_escluse	Offerte escluse dalla procedura	Aggiudicazioni	M2
pct_offerte_escluse	% di offerte escluse sul totale	Aggiudicazioni	M2
tipo_soggetto_agg	Forma giuridica dell'aggiudicatario: singola, ATI, consorzio, SA, GEIE, altro	Aggiudicazioni	M2
lag_aggiudicazione_giorni	Giorni dalla pubblicazione all'aggiudicazione	Aggiudicazioni	M2
lag_comunicazione_esito_giorni	Giorni dalla pubblicazione alla comunicazione dell'esito	CIG	M2
flag_vince_minimo	Aggiudicatario al ribasso minimo (0/1)	Aggiudicazioni	M2
flag_progettazione_esterna	Progettazione esterna alla SA (0/1)	Aggiudicazioni	M2
asta_elettronica	Asta elettronica (0/1)	Aggiudicazioni	M2
flag_scomputo	Scomputo oneri sicurezza dalla cauzione (0/1)	Aggiudicazioni	M2
flag_proc_accelerata	Procedura accelerata ex art. 163 (0/1)	Aggiudicazioni	M2
flag_subappalto	Subappalto dichiarato o autorizzato (0/1)	Aggiudicazioni	M2
Variabili ex post — disponibili dopo la stipula e l'esecuzione		<i>presenti solo in M3</i>	
lag_stipula_aggiudicazione_giorni	Giorni dall'aggiudicazione alla firma del contratto	Contratti	M3
durata_pianificata_giorni	Durata contrattuale prevista (giorni)	Contratti	M3
consegna_frazionata	Consegna in più tranches distinte (0/1/non noto)	Contratti	M3

Continua nella pagina successiva

(segue dalla pagina precedente)

Variabile	Descrizione	Fonte	Fase
consegna_sotto_riserva	Consegna sotto riserva (0/1/non noto)	Contratti	M3
n_varianti	Varianti approvate in corso di esecuzione	Varianti	M3
flag_variante_sostanziale	Almeno una variante sostanziale approvata (0/1)	Varianti	M3
flag_variante_oltre_termine	Prima variante approvata dopo la scadenza (0/1)	Varianti	M3
pct_overrun_variante	Varianti in % dell'importo di aggiudicazione	Quadro economico	M3 [†]
pct_vita_prima_variante	% della durata trascorsa alla prima variante	Varianti	M3 [†]
pct_overrun_core	Rapporto costo finale/iniziale; misura del cost overrun	Quadro economico	M3
pct_riserva_consumata	Somme a disposizione consumate in % del costo iniziale; proxy delle riserve usate	Quadro economico	M3
n_sospensioni	Sospensioni registrate in corso di esecuzione	Sospensioni	M3
durata_totale_sospensioni_gg	Durata totale delle sospensioni (giorni)	Sospensioni	M3
flag_sospensione	Almeno una sospensione registrata (0/1)	Sospensioni	M3
flag_sosp_giudiziaria	Sospensione per ordine giudiziario (0/1)	Sospensioni	M3
pct_durata_sospesa	Sospensioni in % della durata contrattuale	Sospensioni	M3
n_sal	SAL registrati	SAL	M3
flag_in_ritardo	Almeno un SAL in ritardo (0/1/nessun SAL)	SAL	M3
flag_proroga	Proroga registrata nei SAL (0/1)	SAL	M3
esito_collaudo	Esito collaudo: positivo, negativo, non registrato	Collaudi	M3

Tutte le variabili sono estratte dalla Banca Dati Nazionale dei Contratti Pubblici (ANAC).

Fanno eccezione `tasso_disoccupazione` e `tasso_omicidi_100k` (ISTAT) e `reddito_irpef_procapite` (MEF).

[†] Disponibile solo per modelli ad albero (LightGBM, XGBoost) a causa dell'alta percentuale di valori mancanti; esiste la corrispondente variabile binaria per i modelli lineari.

Riferimenti bibliografici

- Gilles Blanchard, Gyemin Lee, and Clayton Scott. Semi-supervised novelty detection. *Journal of Machine Learning Research*, 11:2973–3009, 2010.
- Charles Elkan and Keith Noto. Learning classifiers from only positive and unlabeled data. In *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 213–220, 2008.
- Ryuichi Kiryo, Gang Niu, Marthinus C. du Plessis, and Masashi Sugiyama. Positive-unlabeled learning with non-negative risk estimator. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- Neeraj Kumar et al. PULSNAR: Positive unlabeled learning with selected not-at-random examples. *arXiv preprint*, 2023.
- Bing Liu, Yang Dai, Xiaoli Li, Wee Sun Lee, and Philip S. Yu. Partially supervised classification of text documents. In *Proceedings of the 19th International Conference on Machine Learning*, pages 387–394, 2002.
- Fantine Mordelet and Jean-Philippe Vert. A bagging SVM to learn from positive and unlabeled examples. *Pattern Recognition Letters*, 37:201–209, 2014.
- John C. Platt. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In *Advances in Large Margin Classifiers*, pages 61–74. MIT Press, 1999.
- Harish G. Ramaswamy, Clayton Scott, and Ambuj Tewari. Mixture proportion estimation via kernel embeddings of distributions. In *Proceedings of the 33rd International Conference on Machine Learning*, pages 2254–2262, 2016.
- Tomoya Sakai, Marthinus C. du Plessis, Gang Niu, and Masashi Sugiyama. Semi-supervised classification based on classification from positive and unlabeled data. In *Proceedings of the 34th International Conference on Machine Learning*, pages 2998–3006, 2017.
- Vladimir Vovk, Alexander Gammerman, and Glenn Shafer. *Algorithmic Learning in a Random World*. Springer, 2005.
- Wilton et al. Positive-unlabeled learning with extra trees. In –, 2022.